Pattern Mining (Analisis Asosiasi)

Itemset Mining: Apriori · FP-Growth · Eclat

Pertemuan 11 — Data Mining

Sains Data ITERA · Ganjil 2026/2025

Capaian Pembelajaran & Agenda

> Mahasiswa mampu memahami konsep dasar **itemset mining** dan **analisis asosiasi**, serta mampu menghitung secara manual *frequent itemset* dan *association rule*.

1. Motivasi & aplikasi — *market basket analysis*
2. Definisi formal: itemset, support, confidence, aturan asosiasi
3. Kompleksitas & **prinsip Apriori**
4. **Algoritma Apriori** — perhitungan manual langkah demi langkah
5. Pembangkitan aturan & ukuran *interestingness* (lift, leverage, conviction)
6. **Algoritma FP-Growth** — FP-tree & *conditional pattern base*
7. **Eclat** (format vertikal) · *closed* & *maximal itemset*
8. Implementasi Python · **studi kasus jurnal** · latihan

Motivasi: Apa yang Sering Dibeli Bersamaan?

Setiap transaksi kasir = **keranjang belanja** (himpunan item). Dari jutaan keranjang ingin ditemukan pola seperti:

$$\{\text{Roti}, \text{Susu}\} \Rightarrow \{\text{Mentega}\}$$

Bidang	Contoh pemanfaatan pola asosiasi
Ritel	Penataan rak, *bundling*, promo *cross-selling*
E-commerce	"Sering dibeli bersama" / rekomendasi produk
Kesehatan	Kombinasi gejala/faktor risiko yang sering muncul bersama penyakit
Pendidikan	Pola mata kuliah yang diambil/tidak lulus bersamaan
Web mining	Halaman yang dikunjungi dalam satu sesi
Keamanan	Kombinasi *event* log yang mendahului serangan

Diperkenalkan oleh **Agrawal, Imieliński & Swami (1993)** untuk data transaksi supermarket.

Definisi Formal

- $I = \{i_1, i_2, \ldots, i_d\}$: himpunan semua **item**
- $D = \{t_1, t_2, \ldots, t_N\}$: basis data **transaksi**, tiap $t_j \subseteq I$ memiliki ID (TID)
- **Itemset** $X \subseteq I$; jika $|X| = k$ disebut **k-itemset** — contoh $\{\text{Roti}, \text{Susu}\}$ adalah 2-itemset
- **Support count** — banyaknya transaksi yang memuat X:

$$\sigma(X) = \left|\{\, t_j \in D \;:\; X \subseteq t_j \,\}\right|$$

- **Support** (relatif):

$$s(X) = \frac{\sigma(X)}{N}$$

- X disebut **frequent itemset** jika $s(X) \geq minsup$ (atau $\sigma(X) \geq$ *min support count*)

Contoh: Menghitung Support

TID	Item
1	Roti, Susu
2	Roti, Popok, Bir, Telur
3	Susu, Popok, Bir, Cola
4	Roti, Susu, Popok, Bir
5	Roti, Susu, Popok, Cola

Contoh klasik Tan, Steinbach & Kumar (2019)

Itemset $X = \{\text{Susu}, \text{Popok}, \text{Bir}\}$

Transaksi yang memuat ketiganya: **TID 3 dan 4**

$$\sigma(X) = 2$$

$$s(X) = \frac{2}{5} = 0{,}4 = 40\%$$

Dengan *minsup* = 30%, X **frequent**.

Dengan *minsup* = 50%, X **tidak frequent**.

Aturan Asosiasi (Association Rule)

Aturan berbentuk $X \Rightarrow Y$ dengan $X, Y \subseteq I$ dan $X \cap Y = \emptyset$
(X = *antecedent / LHS*, Y = *consequent / RHS*)

$$\text{support}(X \Rightarrow Y) = s(X \cup Y) = \frac{\sigma(X \cup Y)}{N} \qquad \rightarrow \text{seberapa sering aturan berlaku}$$

$$\text{confidence}(X \Rightarrow Y) = \frac{\sigma(X \cup Y)}{\sigma(X)} = P(Y \mid X) \qquad \rightarrow \text{seberapa dapat dipercaya}$$

Contoh (data slide sebelumnya): $\{\text{Susu}, \text{Popok}\} \Rightarrow \{\text{Bir}\}$

$$s = \frac{\sigma(\text{Susu}, \text{Popok}, \text{Bir})}{N} = \frac{2}{5} = 0{,}4 \qquad c = \frac{\sigma(\text{Susu}, \text{Popok}, \text{Bir})}{\sigma(\text{Susu}, \text{Popok})} = \frac{2}{3} = 0{,}67$$

> Aturan **kuat (strong rule)** jika $s \geq minsup$ **dan** $c \geq minconf$.
> Asosiasi ≠ kausalitas: aturan hanya menyatakan *co-occurrence*.

Masalah Mining Aturan Asosiasi

Diberikan D, *minsup*, *minconf* → **temukan semua** aturan dengan $s \geq minsup$ dan $c \geq minconf$.

Pendekatan dua tahap

1. **Frequent itemset generation** — cari semua itemset dengan $s \geq minsup$ *(bagian paling mahal)*
2. **Rule generation** — dari setiap frequent itemset L, bentuk aturan $A \Rightarrow L \setminus A$ dengan confidence tinggi

Mengapa dua tahap? Semua aturan dari itemset yang sama memiliki **support yang sama**:

$$\{\text{Susu}, \text{Popok}\} \Rightarrow \{\text{Bir}\}, \quad \{\text{Bir}\} \Rightarrow \{\text{Susu}, \text{Popok}\}, \quad \{\text{Popok}, \text{Bir}\} \Rightarrow \{\text{Susu}\}, \ \ldots \qquad s = 0{,}4$$

→ cukup periksa **support itemset**-nya sekali; confidence dihitung belakangan.

Kompleksitas: Mengapa Brute Force Tidak Mungkin?

Dengan d item:

$$\text{jumlah itemset kandidat} = 2^d - 1 \qquad \text{jumlah aturan } R = 3^d - 2^{d+1} + 1$$

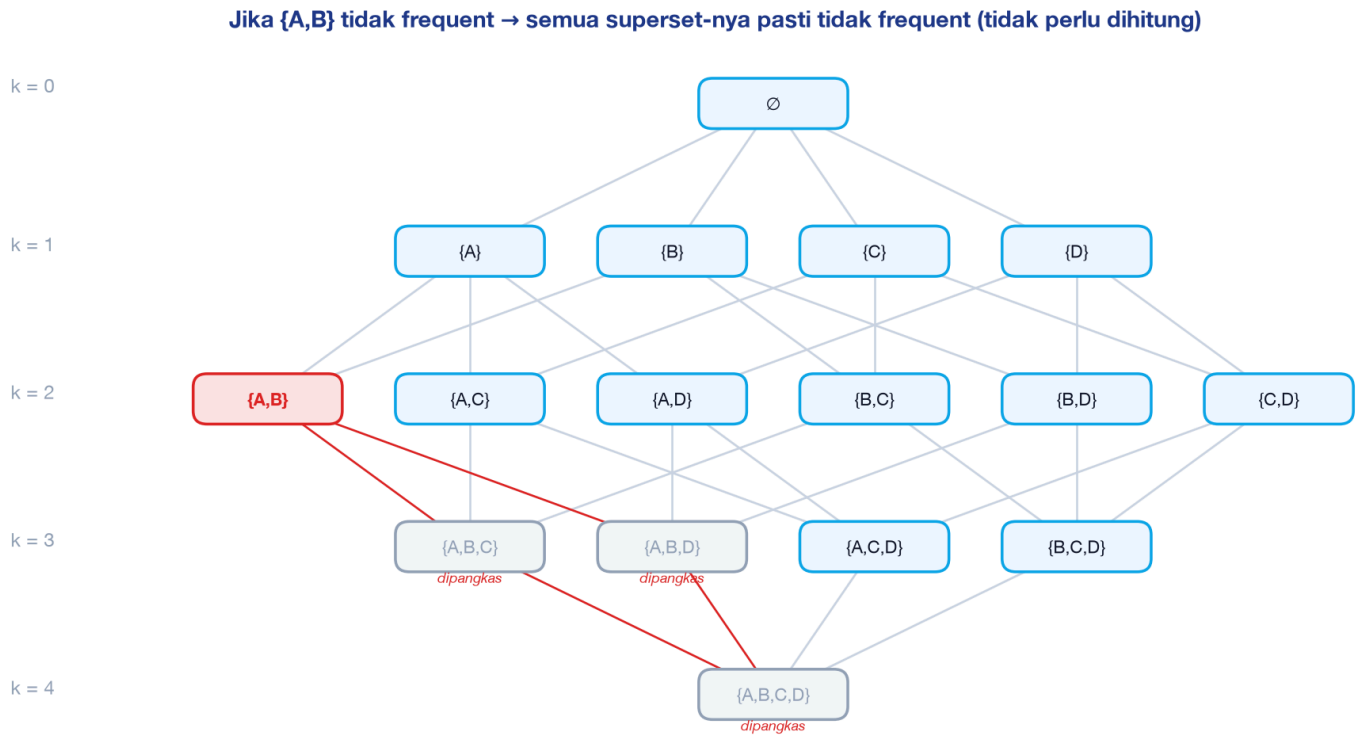
d	Itemset	Aturan
6	63	602
20	≈ 1 juta	≈ $3{,}5 \times 10^9$
100	≈ $1{,}27 \times 10^{30}$	≈ 5×10^{47}

Brute force: cocokkan setiap kandidat ($M = 2^d$) dengan setiap transaksi (N, lebar rata-rata w) → $O(N \cdot M \cdot w)$ — **eksponensial**.

Strategi pengurangan

- Kurangi **jumlah kandidat** M → *pruning* dengan prinsip Apriori
- Kurangi **jumlah perbandingan** NM → struktur data efisien (hash tree, FP-tree, tidset)
- Kurangi **jumlah transaksi/scan** N → FP-Growth, transaction reduction

Itemset Lattice & Prinsip Apriori



Prinsip Apriori: jika sebuah itemset frequent, maka **semua subset-nya pasti frequent**. Sebaliknya, jika sebuah itemset **tidak** frequent, **semua superset-nya pasti tidak frequent**.

Sifat Anti-Monoton Support (Pembuktian)

$$\forall X, Y: \; X \subseteq Y \;\Rightarrow\; s(X) \geq s(Y)$$

Bukti. Ambil sembarang transaksi t yang memuat Y ($Y \subseteq t$).
Karena $X \subseteq Y$, maka $X \subseteq Y \subseteq t \rightarrow t$ juga memuat X.

Jadi $\{t : Y \subseteq t\} \subseteq \{t : X \subseteq t\}$ sehingga $\sigma(Y) \leq \sigma(X)$. ∎

Konsekuensi untuk pruning

Jika $\sigma(\{A, B\}) < minsup$, maka untuk setiap $Y \supseteq \{A, B\}$:

$$\sigma(Y) \leq \sigma(\{A, B\}) < minsup$$

$\rightarrow \{A, B, C\}, \{A, B, D\}, \{A, B, C, D\}$ **tidak perlu dihitung** sama sekali.

Bagian 1 — Algoritma Apriori

Agrawal & Srikant (1994) · *level-wise, generate-and-test*

Algoritma Apriori — Pseudocode

```
Input : D (transaksi), minsup
Output: L = semua frequent itemset

1:  L1 ← { 1-itemset dengan σ ≥ minsup }            // scan D ke-1
2:  for (k = 2; L(k-1) ≠ ∅; k++) do
3:      Ck ← apriori_gen(L(k-1))                     // JOIN + PRUNE
4:      for each transaksi t ∈ D do                   // scan D ke-k
5:          for each kandidat c ∈ Ck, c ⊆ t do  c.count++
6:      Lk ← { c ∈ Ck | c.count ≥ minsup }
7:  return L = ∪k Lk

apriori_gen(L(k-1)):
    // JOIN: gabungkan dua (k-1)-itemset yang k-2 item pertamanya sama (item terurut)
    for p, q ∈ L(k-1) with p[1..k-2] = q[1..k-2] and p[k-1] < q[k-1]:
        c ← p ∪ {q[k-1]}
        // PRUNE: buang c jika ada (k-1)-subset yang tidak ada di L(k-1)
        if every (k-1)-subset s of c ∈ L(k-1):  add c to Ck
```

Ciri: banyak scan basis data (sebanyak panjang itemset terpanjang + 1), tetapi kandidat dipangkas sebelum dihitung.

Studi Hitung Manual: Dataset

TID	Item
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3

Sumber: Han, Kamber & Pei (2012), Tabel 6.1 — *AllElectronics*

Parameter

- $N = 9$ transaksi, $d = 5$ item
- *min support count* = **2** → $minsup = 2/9 \approx 22\%$
- *minconf* = **70%**

Bayangkan item sebagai produk, misalnya I1 = Roti, I2 = Susu, I3 = Mentega, I4 = Kopi, I5 = Selai.

Ruang pencarian brute force: $2^5 - 1 = 31$ itemset.

Iterasi k = 1: $C_1 \rightarrow L_1$

Scan 1 — hitung support count setiap item:

Itemset	Transaksi yang memuat	σ	≥ 2 ?
{I1}	T100, T400, T500, T700, T800, T900	**6**	✓
{I2}	T100, T200, T300, T400, T600, T800, T900	**7**	✓
{I3}	T300, T500, T600, T700, T800, T900	**6**	✓
{I4}	T200, T400	**2**	✓
{I5}	T100, T800	**2**	✓

$$L_1 = \{\{I1\}{:}6,\ \{I2\}{:}7,\ \{I3\}{:}6,\ \{I4\}{:}2,\ \{I5\}{:}2\}$$

Semua item lolos → tidak ada pruning pada level ini.

Iterasi k = 2: $C_2 \rightarrow L_2$

JOIN $L_1 \bowtie L_1 \rightarrow \binom{5}{2} = 10$ kandidat. **PRUNE**: semua 1-subset ada di L_1 → tidak ada yang dibuang. **Scan 2** — hitung support:

Kandidat	Transaksi	σ		Kandidat	Transaksi	σ
{I1,I2}	T100, T400, T800, T900	**4** ✓		{I2,I4}	T200, T400	**2** ✓
{I1,I3}	T500, T700, T800, T900	**4** ✓		{I2,I5}	T100, T800	**2** ✓
{I1,I4}	T400	1 ✗		{I3,I4}	–	0 ✗
{I1,I5}	T100, T800	**2** ✓		{I3,I5}	T800	1 ✗
{I2,I3}	T300, T600, T800, T900	**4** ✓		{I4,I5}	–	0 ✗

$$L_2 = \{\{I1, I2\}{:}4,\ \{I1, I3\}{:}4,\ \{I1, I5\}{:}2,\ \{I2, I3\}{:}4,\ \{I2, I4\}{:}2,\ \{I2, I5\}{:}2\}$$

4 kandidat gugur: {I1,I4}, {I3,I4}, {I3,I5}, {I4,I5}.

> Kandidat yang gugur di sini akan dipakai untuk **memangkas** kandidat level 3 — tanpa perlu menghitungnya.

Iterasi k = 3: JOIN & PRUNE (tanpa scan!)

JOIN — pasangkan anggota L_2 yang item pertamanya sama:

- prefiks I1: {I1,I2}, {I1,I3}, {I1,I5} → {I1,I2,I3}, {I1,I2,I5}, {I1,I3,I5}
- prefiks I2: {I2,I3}, {I2,I4}, {I2,I5} → {I2,I3,I4}, {I2,I3,I5}, {I2,I4,I5}

PRUNE — periksa setiap 2-subset terhadap L_2:

Kandidat	2-subset	Semua di L_2?	Keputusan
{I1,I2,I3}	{I1,I2} ✓ {I1,I3} ✓ {I2,I3} ✓	ya	**dipertahankan**
{I1,I2,I5}	{I1,I2} ✓ {I1,I5} ✓ {I2,I5} ✓	ya	**dipertahankan**
{I1,I3,I5}	{I3,I5} ✗	tidak	dipangkas
{I2,I3,I4}	{I3,I4} ✗	tidak	dipangkas
{I2,I3,I5}	{I3,I5} ✗	tidak	dipangkas
{I2,I4,I5}	{I4,I5} ✗	tidak	dipangkas

→ dari 6 kandidat hasil join hanya **2** yang perlu dihitung di scan berikutnya.

Iterasi k = 3 & 4: Hasil Akhir

Scan 3:

Kandidat	Transaksi	σ	Status
{I1,I2,I3}	T800, T900	**2**	✓ frequent
{I1,I2,I5}	T100, T800	**2**	✓ frequent

$$L_3 = \{\{I1, I2, I3\}{:}2,\ \{I1, I2, I5\}{:}2\}$$

k = 4: JOIN {I1,I2,I3} ⋈ {I1,I2,I5} → {I1,I2,I3,I5}

PRUNE: subset {I1,I3,I5} $\notin L_3$ (juga {I2,I3,I5}) → **dipangkas** → $C_4 = \emptyset$ → **berhenti**.

Ringkasan

	Level 1	Level 2	Level 3	Total
Kandidat dihitung	5	10	2	**17** (bandingkan brute force: 31)
Frequent	5	6	2	**13 frequent itemset**

Bagian 2 — Pembangkitan Aturan

Dari frequent itemset ke *strong association rules*

Algoritma Pembangkitan Aturan

Untuk setiap frequent itemset L dan setiap subset tak-kosong $A \subset L$:

$$A \Rightarrow (L \setminus A) \quad \text{jika} \quad \text{conf} = \frac{\sigma(L)}{\sigma(A)} \geq minconf$$

- Itemset berukuran k menghasilkan $2^k - 2$ kandidat aturan
- **Tidak perlu scan ulang** — semua σ sudah diketahui dari tahap Apriori

Pruning berdasarkan confidence

Untuk itemset L yang sama, memindahkan item dari LHS ke RHS **tidak menaikkan** confidence:

$$\text{conf}(\{I1, I2\} \Rightarrow \{I5\}) \;\geq\; \text{conf}(\{I1\} \Rightarrow \{I2, I5\})$$

karena pembilang sama ($\sigma(L)$) dan $\sigma(\{I1, I2\}) \leq \sigma(\{I1\})$.
→ Jika $A \Rightarrow L \setminus A$ gagal, semua aturan dengan LHS $\subset A$ juga gagal.

Aturan dari $L = \{I1, I2, I5\}$ — σ(L) = 2

Aturan	Perhitungan confidence	conf	≥ 70%?
{I1, I2} ⇒ {I5}	σ(I1,I2,I5) / σ(I1,I2) = 2/4	50%	✗
{I1, I5} ⇒ {I2}	2 / σ(I1,I5) = 2/2	**100%**	✓
{I2, I5} ⇒ {I1}	2 / σ(I2,I5) = 2/2	**100%**	✓
{I1} ⇒ {I2, I5}	2 / σ(I1) = 2/6	33%	✗
{I2} ⇒ {I1, I5}	2 / σ(I2) = 2/7	29%	✗
{I5} ⇒ {I1, I2}	2 / σ(I5) = 2/2	**100%**	✓

Semua aturan ini memiliki support $= 2/9 = 22{,}2\%$.

> Interpretasi: **setiap** pelanggan yang membeli I5 juga membeli I1 dan I2.
> Namun hanya 2 transaksi yang mendukung → perlu hati-hati (lihat ukuran lain).

Aturan dari $L = \{I1, I2, I3\}$ — σ(L) = 2

Aturan	Perhitungan	conf
{I1, I2} ⇒ {I3}	2 / 4	50% ✗
{I1, I3} ⇒ {I2}	2 / 4	50% ✗
{I2, I3} ⇒ {I1}	2 / 4	50% ✗
{I1} ⇒ {I2, I3}	2 / 6	33% ✗
{I2} ⇒ {I1, I3}	2 / 7	29% ✗
{I3} ⇒ {I1, I2}	2 / 6	33% ✗

Tidak ada aturan kuat. Itemset ini **frequent tetapi tidak menghasilkan aturan yang dapat dipercaya**.

> Frequent itemset ≠ aturan yang kuat: support tinggi tidak menjamin confidence tinggi.

Seluruh Strong Rules

Strong rules (*minconf* 70%) dari 13 frequent itemset

Aturan	sup	conf		Aturan	sup	conf
{I5} ⇒ {I1,I2}	22%	100%		{I4} ⇒ {I2}	22%	100%
{I5} ⇒ {I1}	22%	100%		{I5} ⇒ {I2}	22%	100%
{I2,I5} ⇒ {I1}	22%	100%		{I1,I5} ⇒ {I2}	22%	100%

Dari 13 frequent itemset (8 itemset berukuran ≥ 2) diperiksa **24 kandidat aturan** (6 × 2 + 2 × 6); hanya **6** yang lolos *minconf* 70%.

Perhatikan: 5 dari 6 aturan melibatkan I5 atau I4 — item yang **jarang** (σ = 2). Confidence 100% di sini didukung hanya oleh 2 transaksi → butuh ukuran tambahan untuk menilai apakah pola ini menarik.

Confidence Bisa Menyesatkan

Contoh (Han et al., 2012): 10.000 transaksi; 6.000 membeli *game*, 7.500 membeli *video*, 4.000 membeli keduanya.

$$\{\text{game}\} \Rightarrow \{\text{video}\}: \quad s = \frac{4000}{10000} = 40\%, \qquad c = \frac{4000}{6000} = 66{,}7\%$$

Tampak kuat… tetapi peluang **siapa pun** membeli video adalah $P(\text{video}) = 75\% > 66{,}7\%$.

→ membeli *game* justru **menurunkan** peluang membeli video. Confidence mengabaikan support RHS.

Solusi: ukuran korelasi — Lift

$$\text{lift}(X \Rightarrow Y) = \frac{\text{conf}(X \Rightarrow Y)}{s(Y)} = \frac{s(X \cup Y)}{s(X)\, s(Y)} = \frac{0{,}40}{0{,}60 \times 0{,}75} = 0{,}89$$

lift > 1 korelasi positif · **lift = 1** independen · **lift < 1** korelasi negatif

Ukuran Interestingness Lain

Ukuran	Rumus	Rentang	Makna
Lift	$\frac{s(X \cup Y)}{s(X)s(Y)}$	$[0, \infty)$	rasio terhadap independensi
Leverage	$s(X \cup Y) - s(X)s(Y)$	$[-0{,}25, 0{,}25]$	selisih terhadap independensi
Conviction	$\frac{1 - s(Y)}{1 - \text{conf}(X \Rightarrow Y)}$	$[0, \infty]$	> 1: aturan lebih jarang "salah" daripada kebetulan
Kulczynski	$\frac{1}{2}(\text{conf}(X \Rightarrow Y) + \text{conf}(Y \Rightarrow X))$	$[0, 1]$	*null-invariant* (tidak dipengaruhi transaksi yang tidak memuat X maupun Y)

Hitung manual pada data Han

- $\{I5\} \Rightarrow \{I1, I2\}$: lift $= \dfrac{2/9}{(2/9)(4/9)} = \dfrac{9}{4} = \mathbf{2{,}25}$; leverage $= \frac{2}{9} - \frac{2}{9} \cdot \frac{4}{9} = \mathbf{0{,}123}$; conviction $= \dfrac{1 - 4/9}{1 - 1} = \infty$
- $\{I1, I2\} \Rightarrow \{I3\}$: lift $= \dfrac{2/9}{(4/9)(6/9)} = \mathbf{0{,}75}$ → frequent tetapi **berkorelasi negatif**
- $\{I1\} \Rightarrow \{I2\}$: conf $= 4/6$; conviction $= \dfrac{1 - 7/9}{1 - 4/6} = \mathbf{0{,}67} < 1$

Kelemahan Apriori & Perbaikannya

Bottleneck

1. **Kandidat sangat banyak** — 10^4 frequent 1-itemset → $\binom{10^4}{2} \approx 5 \times 10^7$ kandidat 2-itemset
2. **Scan basis data berulang** — untuk pola sepanjang 100 item: $2^{100} \approx 10^{30}$ kandidat & 100+ scan
3. Mencocokkan kandidat dengan transaksi mahal

Teknik peningkatan efisiensi

Teknik	Ide
Hash-based (DHP)	Hash 2-itemset ke *bucket* saat scan 1; bucket < minsup → kandidat dibuang
Transaction reduction	Transaksi tanpa frequent k-itemset tidak dipakai di scan berikutnya
Partitioning	Bagi D menjadi partisi; itemset frequent global pasti frequent di ≥ 1 partisi → 2 scan
Sampling	Mining pada sampel dengan minsup lebih rendah, verifikasi di D
DIC (Brin et al., 1997)	Tambah kandidat baru di tengah scan

Bagian 3 — Algoritma FP-Growth

Han, Pei & Yin (2000) · *pattern growth tanpa candidate generation*

Ide FP-Growth

> Kompres basis data menjadi **FP-tree** (Frequent-Pattern tree) lalu gali pola secara rekursif dengan **divide-and-conquer** — **tanpa membangkitkan kandidat**.

Tiga langkah

1. **Scan 1** — hitung support tiap item, buang yang tidak frequent, urutkan **menurun** berdasarkan support → daftar L
2. **Scan 2** — sisipkan setiap transaksi (item diurutkan sesuai L) ke dalam pohon; prefiks yang sama **berbagi node** dan count-nya ditambah
3. **Mining** — untuk setiap item (dari yang paling jarang): bentuk *conditional pattern base* → *conditional FP-tree* → rekursi

Mengapa urutan menurun?

Item yang paling sering berada dekat root → lebih banyak prefiks yang dapat dibagi → pohon **lebih kompak**.

Basis data hanya di-scan **2 kali**, berapa pun panjang polanya.

Langkah 1: Urutkan Item

Dari scan 1 (sama dengan C_1 Apriori), min support count = 2:

$$L = \langle I2{:}7,\ I1{:}6,\ I3{:}6,\ I4{:}2,\ I5{:}2 \rangle$$

(I1 dan I3 sama-sama 6 → urutan *tie* bebas, asal konsisten.)

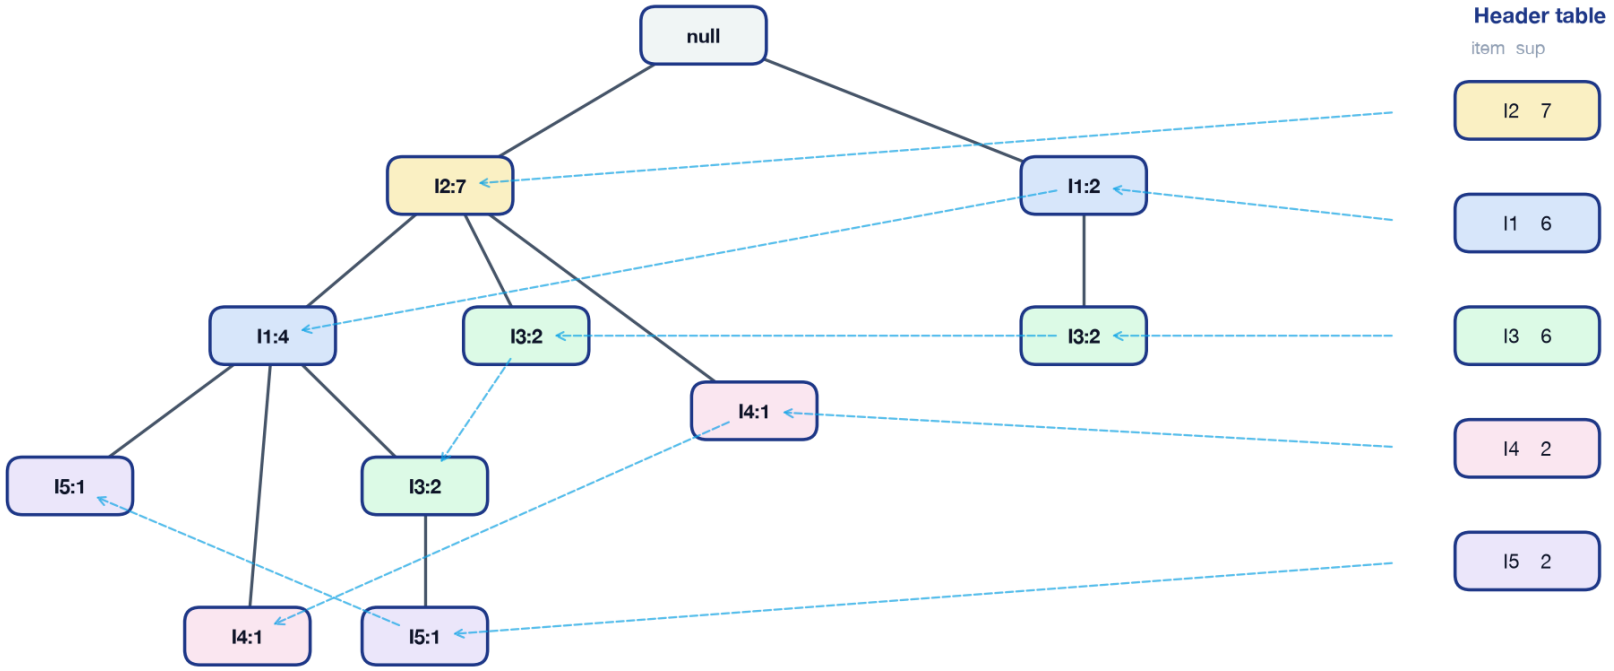
Setiap transaksi **diurutkan ulang** sesuai L:

TID	Asli	Terurut
T100	I1, I2, I5	**I2, I1, I5**
T200	I2, I4	I2, I4
T300	I2, I3	I2, I3
T400	I1, I2, I4	**I2, I1, I4**
T500	I1, I3	I1, I3
T600	I2, I3	I2, I3
T700	I1, I3	I1, I3
T800	I1, I2, I3, I5	**I2, I1, I3, I5**
T900	I1, I2, I3	**I2, I1, I3**

Langkah 2: sisipkan ke pohon (scan 2)

Sisip	Perubahan pada pohon
T100	null→**I2:1**→**I1:1**→**I5:1** (cabang baru)
T200	I2:**2**, buat anak **I4:1**
T300	I2:**3**, buat anak **I3:1**
T400	I2:**4**→I1:**2**, buat anak **I4:1**
T500	prefiks berbeda → cabang baru null→**I1:1**→**I3:1**
T600	I2:**5**→I3:**2**
T700	I1:**2**→I3:**2** (cabang kanan)
T800	I2:**6**→I1:**3**, buat **I3:1**→**I5:1**
T900	I2:**7**→I1:**4**→I3:**2**

Langkah 2: FP-tree Hasil



garis putus-putus biru = node-link (menghubungkan node dengan item yang sama)

9 transaksi (23 kemunculan item) dipadatkan menjadi **10 node** + header table.

Jumlah count pada node-link suatu item = support item tersebut (contoh I3: 2 + 2 + 2 = 6 ✓).

Langkah 3: Conditional Pattern Base

Proses item **dari bawah** header table (support terkecil): I5, I4, I3, I1.

Conditional pattern base item x = kumpulan **prefix path** menuju node x, dengan count = count node x.

Item	Conditional pattern base	Conditional FP-tree (σ ≥ 2)	Frequent pattern yang dihasilkan
I5	{I2, I1: 1}, {I2, I1, I3: 1}	⟨I2:2, I1:2⟩ *(I3:1 dibuang)*	{I2,I5}:2, {I1,I5}:2, {I2,I1,I5}:2
I4	{I2, I1: 1}, {I2: 1}	⟨I2:2⟩ *(I1:1 dibuang)*	{I2,I4}:2
I3	{I2, I1: 2}, {I2: 2}, {I1: 2}	⟨I2:4, I1:2⟩, ⟨I1:2⟩	{I2,I3}:4, {I1,I3}:4, {I2,I1,I3}:2
I1	{I2: 4}	⟨I2:4⟩	{I2,I1}:4

Ditambah 5 frequent 1-itemset → **13 frequent itemset**, **identik** dengan hasil Apriori ✓

Detail Rekursi: Item I5 dan I3

Item I5

1. Telusuri node-link I5: dua node
   - I2:7 → I1:4 → **I5:1** ⇒ prefix {I2, I1} count **1**
   - I2:7 → I1:4 → I3:2 → **I5:1** ⇒ prefix {I2, I1, I3} count **1**
2. Hitung support di dalam base: I2 = 1+1 = **2** ✓, I1 = **2** ✓, I3 = **1** ✗
3. Conditional FP-tree (satu jalur): ⟨I2:2, I1:2⟩
4. Jalur tunggal → **semua kombinasi** item jalur + suffix I5: {I2,I5}:2, {I1,I5}:2, {I2,I1,I5}:2

Item I3

1. Prefix path: {I2,I1}:2, {I2}:2, {I1}:2
2. Support: I2 = 2+2 = **4**, I1 = 2+2 = **4**
3. Conditional tree **bercabang**: null → I2:4 → I1:2 dan null → I1:2
4. Pola langsung: {I2,I3}:4, {I1,I3}:4
5. **Rekursi** pada tree kondisional I3 untuk suffix {I1,I3}: base = {I2: 2} → σ(I2) = 2 ✓ → **{I2,I1,I3}:2**

> **Inti FP-Growth**: masalah "cari pola berakhiran x" direduksi menjadi mining pada basis data kondisional yang jauh lebih kecil.

Apriori vs FP-Growth

Aspek	Apriori	FP-Growth
Strategi	*Breadth-first*, generate-and-test	*Depth-first*, pattern growth (divide & conquer)
Kandidat	Dibangkitkan eksplisit (bisa sangat banyak)	**Tidak ada** candidate generation
Scan basis data	$k_{max} + 1$ kali	**2 kali**
Memori	Menyimpan kandidat per level	Menyimpan FP-tree (bisa besar jika data *sparse*)
Kinerja	Lambat pada minsup rendah / pola panjang	Umumnya jauh lebih cepat, terutama data padat
Implementasi	Sederhana, mudah dijelaskan	Lebih kompleks (pointer, rekursi)
Hasil	**Sama persis** (algoritma *exact*)	**Sama persis**

Han et al. (2000) melaporkan FP-Growth sekitar **satu orde besaran lebih cepat** daripada Apriori pada dataset uji mereka.

Bagian 4 — Eclat & Representasi Ringkas

Format data vertikal · Closed & Maximal itemset

Eclat: Format Data Vertikal (Zaki, 2000)

Ubah format **horizontal** (TID → item) menjadi **vertikal** (item → *TID-set*):

Item	TID-set	σ
I1	{T100, T400, T500, T700, T800, T900}	6
I2	{T100, T200, T300, T400, T600, T800, T900}	7
I3	{T300, T500, T600, T700, T800, T900}	6
I4	{T200, T400}	2
I5	{T100, T800}	2

Kunci: $t(X \cup Y) = t(X) \cap t(Y)$ dan $\sigma(X) = |t(X)|$ → support dihitung dengan **irisan himpunan**, tanpa scan ulang basis data.

Contoh 2-itemset

- $t(I1) \cap t(I2)$ = {T100, T400, T800, T900} → σ = **4** ✓
- $t(I1) \cap t(I5)$ = {T100, T800} → σ = **2** ✓
- $t(I3) \cap t(I5)$ = {T800} → σ = 1 ✗

Contoh 3-itemset

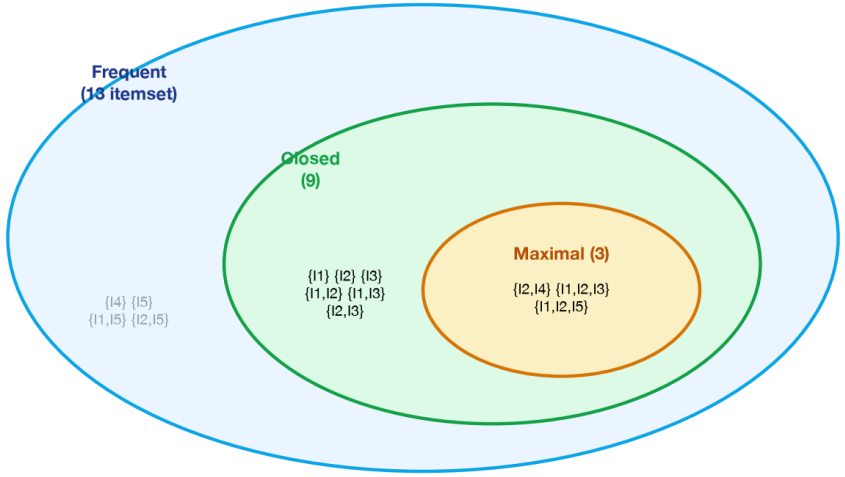
- $t(I1, I2) \cap t(I1, I3)$ = {T800, T900} → {I1,I2,I3}: σ = **2** ✓
- $t(I1, I2) \cap t(I1, I5)$ = {T100, T800} → {I1,I2,I5}: σ = **2** ✓

Diffset (dEclat): simpan selisih $t(X) \setminus t(XY)$ agar memori lebih hemat pada data padat.

Closed & Maximal Frequent Itemset

Jumlah frequent itemset bisa meledak (pola sepanjang 100 → 2^{100} subset frequent). Diperlukan representasi ringkas.

- **Closed**: X frequent dan **tidak ada superset** $Y \supset X$ dengan $\sigma(Y) = \sigma(X)$ → *lossless*, support semua frequent itemset dapat dipulihkan
- **Maximal**: X frequent dan **tidak ada superset** yang frequent → paling ringkas, tetapi informasi support hilang



Contoh: {I5}:2 **tidak closed** karena {I1,I2,I5}:2 memiliki support yang sama. {I1,I2}:4 **closed** tetapi tidak maximal ({I1,I2,I3} frequent).

Bagian 5 — Implementasi & Studi Kasus

Implementasi Python (mlxtend)

```python
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import (
    apriori, fpgrowth, association_rules)

transaksi = [["I1","I2","I5"], ["I2","I4"],
  ["I2","I3"], ["I1","I2","I4"], ["I1","I3"],
  ["I2","I3"], ["I1","I3"],
  ["I1","I2","I3","I5"], ["I1","I2","I3"]]

te = TransactionEncoder()          # one-hot
df = pd.DataFrame(
    te.fit(transaksi).transform(transaksi),
    columns=te.columns_)

fi = apriori(df, min_support=2/9,
             use_colnames=True)    # atau fpgrowth(...)
rules = association_rules(
    fi, num_itemsets=len(df),
    metric="confidence", min_threshold=0.7)
print(rules[["antecedents", "consequents",
  "support", "confidence", "lift"]])
```

Output (diuji dengan mlxtend 0.25.0):

```
antecedents  consequents  support  conf   lift
{I5}         {I1, I2}       0.222   1.0  2.250
{I5}         {I1}           0.222   1.0  1.500
{I5, I2}     {I1}           0.222   1.0  1.500
{I4}         {I2}           0.222   1.0  1.286
{I5, I1}     {I2}           0.222   1.0  1.286
{I5}         {I2}           0.222   1.0  1.286
```

✓ 13 frequent itemset & 6 strong rules — sama dengan hitungan manual.

✓ `apriori` dan `fpgrowth` menghasilkan himpunan itemset yang identik.

Kode lengkap: `dm/p11_itemset_mining_demo.py`

Alur Kerja Market Basket Analysis

Tahap	Kegiatan
1. Data transaksi	Data POS / e-commerce: TID, item, waktu, jumlah
2. Pra-pemrosesan	Hapus retur/batal, gabung baris per invoice, normalisasi nama produk, agregasi ke kategori bila item terlalu banyak
3. Encoding	One-hot: matriks *basket* × *item* (True/False)
4. Mining	Apriori / FP-Growth dengan *minsup*, lalu bangkitkan aturan dengan *minconf*
5. Evaluasi	Saring dengan lift > 1, urutkan, diskusikan dengan pakar domain
6. Aksi bisnis	*Bundling*, tata letak rak, rekomendasi produk, promo silang

Memilih ambang batas

- *minsup* terlalu tinggi → hanya pola "jelas" (roti–susu); item mahal tapi jarang hilang (**rare item problem**)
- *minsup* terlalu rendah → ledakan jumlah itemset & aturan
- Praktik: mulai dari *minsup* 1–5% (data ritel *sparse*), *minconf* 30–70%, lalu **saring dengan lift > 1**
- Validasi aturan dengan pakar domain & uji A/B sebelum diterapkan

Studi Kasus 1 — Keputusan Assortment Produk Ritel

Brijs, Swinnen, Vanhoof & Wets (1999). *Using Association Rules for Product Assortment Decisions: A Case Study.* Proc. KDD-99, ACM, pp. 254–260.

Data	Transaksi kasir supermarket di Belgia
Masalah	Produk mana yang layak dipertahankan di rak terbatas? Menilai produk hanya dari profit individual mengabaikan efek *cross-selling*
Metode	Frequent itemset → model optimasi **PROFSET** yang memperhitungkan profit dari itemset yang dibeli bersama
Temuan	Produk dengan profit sendiri rendah bisa tetap penting karena "menarik" pembelian produk lain

> Pelajaran: frequent itemset bukan tujuan akhir — ia menjadi **masukan** model keputusan bisnis.

Studi Kasus 2 — Kesehatan: Prediksi Penyakit Jantung

Ordonez, C. (2006). *Association Rule Discovery with the Train and Test Approach for Heart Disease Prediction.* IEEE Transactions on Information Technology in Biomedicine, 10(2), 334–343.

Data	Rekam medis pasien (faktor risiko, hasil pemeriksaan, kondisi pembuluh darah jantung)
Masalah	Jumlah aturan yang dihasilkan sangat besar dan banyak yang tidak relevan secara medis
Metode	Aturan asosiasi dengan **batasan** (misalnya hanya atribut diagnosis di RHS, panjang aturan dibatasi) + validasi **train–test**
Pelajaran	Aturan harus diuji pada data yang tidak dipakai saat mining agar tidak sekadar *overfitting* pola kebetulan

> Pola asosiasi dapat dipakai untuk **pendukung keputusan klinis**, bukan pengganti diagnosis dokter.

Studi Kasus 3 — Penelitian di Indonesia

Studi	Data & metode	Hasil yang dilaporkan
Toko aksesori skuter, Denpasar — *JAIC* (Politeknik Negeri Batam), 2025	23.381 transaksi (Jan–Ags 2024), **FP-Growth**	16 aturan pada *minsup* 1%, *minconf* 50% → desain promo *bundling*
Minimarket Darvina Mart — *JINSENG* (ITK)	Transaksi pelanggan, **FP-Growth** (RapidMiner)	14 aturan dengan lift > 1
Grosir sembako — *JATI* (ITN Malang), 2026	**Apriori** + kerangka CRISP-DM, Python	Rekomendasi strategi promosi produk
Implementasi Apriori berbasis R — *ELTIKOM*, 2018	Data penjualan contoh, **Apriori**	Hasil terbaik pada support 0,1; confidence 0,8; lift > 1

Dataset latihan publik: *Online Retail* (UCI ML Repository) — ±540 ribu baris transaksi ritel online Inggris 2010–2011 (Chen, Sain & Guo, 2012).

> Tugas mandiri: baca salah satu artikel di atas, lalu identifikasi parameter (*minsup*, *minconf*), jumlah aturan, dan bagaimana lift dipakai.

Latihan Hitung Manual

TID	Item
1	Roti, Susu, Telur
2	Roti, Susu
3	Susu, Kopi
4	Roti, Telur
5	Roti, Susu, Kopi, Telur
6	Susu, Telur

min support count = **3** (50%) · *minconf* = **60%**

Kerjakan

1. Jalankan Apriori: tuliskan C_1, L_1, C_2, L_2, C_3 beserta langkah *prune*
2. Mengapa {Roti, Susu, Telur} **tidak** dipangkas pada tahap prune, tetapi tetap tidak frequent?
3. Bangun FP-tree (urutkan item sesuai support)
4. Bangkitkan semua strong rules dan hitung lift masing-masing
5. Aturan mana yang paling layak dipakai untuk promosi? Jelaskan dengan lift.

Kunci Jawaban Latihan

C_1: Roti 4, Susu 5, Telur 4, Kopi 2 ✗
L_1 = {Roti, Susu, Telur}

C_2: {Roti,Susu} 3 ✓, {Roti,Telur} 3 ✓, {Susu,Telur} 3 ✓
L_2 = ketiganya

C_3: join → {Roti,Susu,Telur}; semua 2-subset ada di L_2 → **lolos prune**, tetapi σ = 2 (TID 1, 5) < 3 → **tidak frequent**.
Prune hanya syarat perlu, bukan syarat cukup.

Urutan FP-tree: Susu:5, Roti:4, Telur:4

Aturan (semua support 50%):

Aturan	conf	lift
Roti ⇒ Susu	3/4 = 75%	0,90
Susu ⇒ Roti	3/5 = 60%	0,90
Roti ⇒ Telur	3/4 = 75%	**1,125**
Telur ⇒ Roti	3/4 = 75%	**1,125**
Susu ⇒ Telur	3/5 = 60%	0,90
Telur ⇒ Susu	3/4 = 75%	0,90

Hanya **Roti dan Telur** yang berkorelasi positif (lift > 1). Aturan dengan Susu: confidence tinggi karena Susu memang dibeli 83% pelanggan, bukan karena asosiasi.

Ringkasan

- **Itemset mining** mencari himpunan item yang sering muncul bersama; **aturan asosiasi** $X \Rightarrow Y$ diukur dengan support & confidence
- Ruang pencarian eksponensial ($2^d - 1$); kuncinya adalah **sifat anti-monoton support** (prinsip Apriori)
- **Apriori**: level-wise, *join* + *prune*, banyak scan; mudah dipahami
- **FP-Growth**: kompres ke FP-tree, 2 scan, rekursi *conditional pattern base*, tanpa kandidat
- **Eclat**: format vertikal, support = ukuran irisan TID-set
- Semua algoritma *exact* → **hasil sama**; yang berbeda adalah efisiensi
- Confidence saja bisa menyesatkan → gunakan **lift**, leverage, conviction, ukuran *null-invariant*
- **Closed** (lossless) dan **maximal** (paling ringkas) untuk merangkum pola
- Studi kasus: frequent pattern adalah **masukan** keputusan (assortment, promosi, klinis) dan perlu validasi

Pertemuan berikutnya: Graph Mining (*Community Detection*)

Referensi

1. Agrawal, R., Imieliński, T., & Swami, A. (1993). Mining association rules between sets of items in large databases. *Proc. ACM SIGMOD*, 207–216.
2. Agrawal, R., & Srikant, R. (1994). Fast algorithms for mining association rules. *Proc. 20th VLDB*, 487–499.
3. Han, J., Pei, J., & Yin, Y. (2000). Mining frequent patterns without candidate generation. *Proc. ACM SIGMOD*, 1–12.
4. Zaki, M. J. (2000). Scalable algorithms for association mining. *IEEE Trans. Knowledge and Data Engineering*, 12(3), 372–390.
5. Brin, S., Motwani, R., Ullman, J. D., & Tsur, S. (1997). Dynamic itemset counting and implication rules for market basket data. *Proc. ACM SIGMOD*, 255–264.
6. Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.), Bab 6. Morgan Kaufmann.
7. Tan, P.-N., Steinbach, M., Karpatne, A., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.), Bab 5. Pearson.
8. Fournier-Viger, P., Lin, J. C.-W., Vo, B., Chi, T. T., Zhang, J., & Le, H. B. (2017). A survey of itemset mining. *WIREs Data Mining and Knowledge Discovery*, 7(4), e1207.
9. Brijs, T., Swinnen, G., Vanhoof, K., & Wets, G. (1999). Using association rules for product assortment decisions: A case study. *Proc. KDD-99*, 254–260.
10. Ordonez, C. (2006). Association rule discovery with the train and test approach for heart disease prediction. *IEEE Trans. Inf. Technol. Biomed.*, 10(2), 334–343.
11. Chen, D., Sain, S. L., & Guo, K. (2012). Data mining for the online retail industry: A case study of RFM model-based customer segmentation. *J. Database Marketing & Customer Strategy Management*, 19, 197–208.
12. Khadka, G. *Mining Frequent Pattern and Association*. Medium. https://khadkagopal.medium.com/mining-frequent-pattern-and-association-dffead065ca5
13. Studi kasus Indonesia: jurnal.polibatam.ac.id/index.php/JAIC · journal.itk.ac.id/index.php/jinseng/article/view/897 · ejournal.itn.ac.id/jati/article/download/18177/9517 · core.ac.uk/download/200949667.pdf