Panduan Tugas Akhir: Penelitian Machine Learning & Deep Learning

> Dari ide hingga sidang — menyusun skripsi yang **terukur, reproducible, dan dapat dipertanggungjawabkan**

Untuk Mahasiswa dengan Pembimbing · Ahmad Luky Ramdani · Program Studi Sains Data · ITERA

Agenda

#	Topik
0	**Gambaran umum** — alur tugas akhir & karakter penelitian ML/DL
1	**Bab 1 Pendahuluan** — latar belakang, masalah, premis, hipotesis, tujuan, batasan
2	**Bab 2 Tinjauan Pustaka** — state of the art & *research gap*
3	**Bab 3 Metodologi** — data, model, eksperimen, evaluasi
4	**Bab 4 Hasil & Pembahasan** — menyajikan dan menafsirkan hasil
5	**Bab 5 Kesimpulan & Saran**
6	**Manajemen penelitian** — jadwal, bimbingan, tools, etika, checklist

> Contoh judul skripsi: **"Klasifikasi Penyakit Daun Padi Berbasis Citra Menggunakan Transfer Learning"**.

0. Gambaran Umum

Apa yang membuat skripsi ML/DL berbeda?

Skripsi ML/DL = Penelitian Eksperimental

Skripsi ML/DL **bukan** "membuat aplikasi yang memakai model", melainkan **menjawab pertanyaan penelitian melalui eksperimen terkontrol**.

Bukan ini	Melainkan ini
"Membangun sistem deteksi penyakit padi"	"Seberapa besar transfer learning meningkatkan F1 dibanding CNN dari awal pada data terbatas?"
Hanya melaporkan "akurasi 98%"	Membandingkan dengan **baseline**, menjelaskan **mengapa**, dan menguji **signifikansi**
Satu kali *training*	Beberapa *seed*, *cross-validation*, *ablation*
Kode di laptop pribadi	Kode, data, dan konfigurasi **berversi & dapat diulang**

> Kontribusi skripsi S1 tidak harus metode baru. Cukup: **penerapan yang tepat + perbandingan yang adil + analisis yang jujur** pada masalah/data yang relevan.

Alur Besar Tugas Akhir

Tahap	Keluaran	Bab
1. Eksplorasi topik & literatur	Daftar 20–40 paper, peta *research gap*	1, 2
2. Proposal	Rumusan masalah, hipotesis, rancangan eksperimen	1–3
3. Pengumpulan & persiapan data	Dataset berversi, laporan EDA	3
4. Baseline	Model sederhana + angka acuan	3, 4
5. Eksperimen utama	Hasil model usulan, tuning, ablation	4
6. Analisis	Uji statistik, *error analysis*, interpretasi	4
7. Penulisan & sidang	Naskah lengkap, slide, kode & data terarsip	1–5

> Tulis **sambil** bereksperimen — jangan menunggu semua eksperimen selesai baru menulis.

Tipe Kontribusi yang Layak untuk S1

Tipe	Contoh	Catatan
Studi komparatif	Membandingkan CNN, ResNet, EfficientNet, ViT pada citra daun padi	Paling umum; wajib adil (setting sama)
Penerapan pada domain/data baru	IndoBERT untuk ulasan aplikasi pemerintah daerah	Nilai pada **dataset & konteks lokal**
Pembuatan dataset	Korpus beranotasi bahasa Lampung	Wajib ukur kualitas anotasi (Cohen's κ)
Modifikasi/perbaikan kecil	Menambahkan *attention* atau augmentasi khusus	Butuh *ablation study*
Analisis/interpretabilitas	Mengapa model gagal pada kelas tertentu (Grad-CAM, SHAP)	Fokus pada *insight*
Efisiensi	Kuantisasi model agar jalan di HP petani	Ukur akurasi **dan** latensi/ukuran

Bab 1. Pendahuluan

Latar belakang · Rumusan masalah (masalah, premis, hipotesis) · Tujuan · Batasan

Struktur Bab 1

Subbab	Pertanyaan yang dijawab
A. Latar Belakang	Mengapa masalah ini penting? Apa yang sudah dilakukan? Apa yang belum?
	(jangan ada kalimat atau opini pribadi, tapi harus berdasarkan paper)
B. Rumusan Masalah	*di dalamnya terdapat masalah penelitian, premis dan hipotesis*
B.1 Masalah penelitian	Pertanyaan **spesifik** apa yang ingin dijawab?
B.2 Premis	Fakta/temuan terdahulu apa yang menjadi **pijakan**? *(bersumber dari paper)*
B.3 Hipotesis	**Dugaan sementara** apa yang akan diuji?
C. Tujuan Penelitian	Apa yang akan dihasilkan untuk menjawab masalah?
D. Batasan Penelitian	Apa yang **tidak** dicakup, dan mengapa?

> Bab 1 adalah "kontrak" penelitian: semua yang dijanjikan di sini **harus terjawab** di Bab 4 dan 5.

A. Latar Belakang

1. **Konteks luas** — masalah nyata + data/angka. *"Padi adalah makanan pokok…; penyakit blas dan hawar daun menyebabkan kehilangan hasil hingga X% (sumber)."*
2. **Masalah praktis** — *"Identifikasi manual oleh penyuluh lambat dan jumlah penyuluh terbatas."*
3. **Peluang solusi** — *"Deep learning telah berhasil pada klasifikasi citra tanaman (Mohanty dkk., 2016)."*
4. **Celah (*gap*)** — *"Namun, sebagian besar studi memakai citra laboratorium berlatar seragam; kinerja pada citra lapangan dengan data terbatas belum banyak dikaji."*
5. **Usulan** — *"Penelitian ini mengkaji transfer learning untuk citra lapangan…"*

> Setiap klaim di latar belakang **wajib bersitasi** (jurnal/data resmi), bukan opini.

Kesalahan Umum di Latar Belakang

✗ Hindari	✓ Lebih baik
"Di era revolusi industri 4.0 yang semakin canggih…"	Langsung ke masalah konkret + angka
"Deep learning adalah metode terbaik"	"Deep learning menunjukkan kinerja tinggi pada … (sitasi)"
Memilih metode dulu, mencari masalah belakangan	Masalah → kebutuhan → pemilihan metode yang beralasan
Tidak menyebut penelitian terdahulu	Ringkas 3–5 studi paling dekat + kelemahannya
Gap tidak jelas ("belum ada yang meneliti di ITERA")	*Gap* metodologis/data: kondisi data, bahasa, skala, metrik
Paragraf panjang tanpa alur	Satu paragraf = satu gagasan; ikuti pola corong

> Uji cepat: setelah membaca latar belakang, pembaca harus bisa menebak **rumusan masalah** Anda.

B.1 Masalah Penelitian

Rumusan masalah ML/DL yang baik bersifat **spesifik, terukur, dan dapat dijawab dengan eksperimen**.

✗ Kabur/Bias	✓ Spesifik & terukur
Bagaimana membuat sistem deteksi penyakit padi?	Bagaimana kinerja (F1-macro) transfer learning EfficientNet-B0 dibandingkan CNN yang dilatih dari awal pada citra lapangan daun padi?
Apakah deep learning akurat?	Bagaimana pengaruh augmentasi data terhadap kinerja model ketika jumlah data latih hanya 100 citra per kelas?
Bagaimana menerapkan BERT?	Kelas penyakit apa yang paling sering salah diklasifikasikan, dan apa penyebabnya?

> Rumus praktis: **[pengaruh/perbandingan] + [variabel/metode] + [metrik] + [kondisi data/konteks]**.

B.2 Premis

Premis = pernyataan yang **sudah diterima kebenarannya** (didukung literatur/fakta), menjadi pijakan logis menuju hipotesis.

Contoh:

- **P1.** CNN yang dilatih pada ImageNet mempelajari fitur visual umum (tepi, tekstur, bentuk) yang dapat dipindahkan ke domain lain *(Yosinski dkk., 2014)*.
- **P2.** Transfer learning meningkatkan kinerja ketika data latih domain target terbatas *(Pan & Yang, 2010)*.
- **P3.** Gejala penyakit daun padi terutama dibedakan oleh **pola tekstur dan warna** bercak.
- **P4.** Dataset citra lapangan yang tersedia relatif kecil (< 1.000 citra per kelas).

> Premis bukan hipotesis: premis **tidak diuji** dalam penelitian Anda, tetapi **dikutip** dari bukti yang sudah ada.

B.3 Hipotesis

Hipotesis = **dugaan yang dapat diuji** dan diturunkan dari premis. Dalam ML/DL nyatakan dalam **metrik** dan **pembanding**.

Dari P1 + P2 + P4 →

- **H_1:** Model EfficientNet-B0 dengan transfer learning menghasilkan F1-macro **lebih tinggi secara signifikan** dibanding CNN yang dilatih dari awal pada data citra lapangan daun padi.
- **H_0:** Tidak ada perbedaan F1-macro yang signifikan antara kedua pendekatan.

$$H_0 : \mu_{F1}^{\text{TL}} = \mu_{F1}^{\text{scratch}} \qquad H_1 : \mu_{F1}^{\text{TL}} > \mu_{F1}^{\text{scratch}}$$

> Hipotesis menentukan **desain eksperimen**: apa yang dibandingkan, metrik apa, berapa kali diulang, dan uji statistik apa (dibahas di Bab 3).

Keterkaitan Masalah → Premis → Hipotesis → Tujuan

Masalah (B.1)	Premis (B.2)	Hipotesis (B.3)	Tujuan (C)	Dijawab di
RM1: Bagaimana kinerja TL vs CNN dari awal?	P1, P2, P4	H1: TL > scratch (F1-macro, signifikan)	T1: Mengukur & membandingkan F1-macro keduanya	Bab 4.2, uji Wilcoxon
RM2: Bagaimana pengaruh augmentasi pada data terbatas?	P2, P4	H2: Augmentasi menaikkan F1 pada 100 citra/kelas	T2: Menganalisis efek augmentasi lewat ablation	Bab 4.3
RM3: Kelas apa yang paling sulit & mengapa?	P3	— (eksploratif)	T3: Menganalisis kesalahan dengan confusion matrix & Grad-CAM	Bab 4.4

> Gunakan **tabel keterlacakan** seperti ini di catatan bimbingan. Setiap baris harus muncul lagi sebagai **satu poin kesimpulan** di Bab 5.

C. Tujuan Penelitian

- Tujuan adalah **cermin** rumusan masalah: jumlahnya sama, urutannya sama.
- Gunakan kata kerja operasional: *mengukur, membandingkan, menganalisis, mengevaluasi, membangun*.

Rumusan Masalah	Tujuan
Bagaimana kinerja TL dibanding CNN dari awal…?	**Membandingkan** F1-macro TL EfficientNet-B0 dan CNN dari awal…
Bagaimana pengaruh augmentasi…?	**Menganalisis** pengaruh augmentasi terhadap F1-macro…
Kelas apa yang paling sulit…?	**Mengidentifikasi** pola kesalahan klasifikasi beserta penyebabnya…

Opsional: **Manfaat penelitian** — teoretis (bukti empiris), praktis (alat bantu penyuluh), dan dataset/kode terbuka.

D. Batasan Penelitian

Batasan membuat penelitian **dapat diselesaikan** dalam 1–2 semester dan menjelaskan **lingkup klaim**.

Aspek	Contoh batasan
Data	Citra dari dataset publik X + 300 citra lapangan Lampung Selatan; 4 kelas (blas, hawar, tungro, sehat)
Tugas	Klasifikasi citra tunggal; **tidak** termasuk deteksi lokasi bercak (object detection) atau tingkat keparahan
Model	CNN sederhana (baseline), ResNet-50, EfficientNet-B0; **tidak** membangun arsitektur baru
Sumber daya	Pelatihan dengan GPU Google Colab/Kaggle (T4, 16 GB)
Evaluasi	Offline pada test set; **tidak** diuji langsung oleh petani di lapangan
Bahasa/wilayah	(untuk NLP) teks berbahasa Indonesia dari platform X periode Jan–Jun 2026

> Batasan ≠ kelemahan yang ditutupi. Batasan **dipilih dengan alasan**; kelemahan yang ditemukan kemudian ditulis di Bab 5 (saran).

Bab 2. Tinjauan Pustaka

State of the art · Landasan teori · Research gap

Isi Bab 2

2.1 Penelitian Terkait (*state of the art*)

Studi terdahulu yang **paling dekat** dengan topik — dibandingkan secara kritis, bukan diringkas satu per satu.

2.2 Landasan Teori

Konsep yang **dipakai** di Bab 3: CNN, transfer learning, fungsi loss, optimizer, metrik evaluasi, uji statistik. Sertakan persamaan dan notasi yang konsisten.

> Aturan praktis: **jangan** menulis teori yang tidak dipakai. Jika Bab 3 tidak memakai SVM, SVM tidak perlu dijelaskan panjang di Bab 2.

Mencari Literatur yang Tepat

Sumber	Kegunaan
Google Scholar, Semantic Scholar	Pencarian umum, jejak sitasi (*cited by*)
Papers with Code	Benchmark, kode, dataset, SOTA per tugas
arXiv	Preprint terbaru (cek apakah sudah terbit di jurnal/konferensi)
IEEE Xplore, ScienceDirect, ACM DL, SpringerLink	Jurnal & prosiding bereputasi
SINTA, Garuda	Penelitian berkonteks Indonesia
Connected Papers, ResearchRabbit	Peta keterkaitan paper

Strategi: mulai dari **1–2 survei/review terbaru** → telusuri referensinya (*backward*) dan yang mengutipnya (*forward*). Kelola dengan **Zotero/Mendeley** sejak hari pertama.

> Utamakan publikasi **5 tahun terakhir** + paper fondasional (mis. ResNet, Transformer). Hindari blog/Medium sebagai rujukan utama.

Matriks Literatur (*Literature Matrix*)

Bandingkan studi terdahulu dalam **satu tabel** — dari sini *research gap* terlihat. Kolom yang ditampilkan sesuaikan dengan fotmat prodi

Penulis (tahun)	Data	Kondisi citra	Metode	Metrik	Hasil	Keterbatasan
Mohanty dkk. (2016)	PlantVillage, 54K citra, 38 kelas	Laboratorium, latar seragam	AlexNet, GoogLeNet (TL)	Akurasi	99,35%	Turun drastis pada citra lapangan
Studi B (2021)	Daun padi, 5.932 citra	Campuran	VGG16, ResNet50	Akurasi, F1	F1 0,95	Tanpa uji signifikansi; 1 kali run
Studi C (2023)	Daun padi lapangan, 1.200 citra	Lapangan	CNN custom	Akurasi	88%	Tidak dibandingkan dengan TL
Studi D (2024)	Daun padi	Lapangan	ViT	F1	0,91	Butuh data besar; biaya komputasi tinggi
Penelitian ini	Publik + 300 citra Lampung	**Lapangan, data terbatas**	**CNN vs ResNet vs EfficientNet**	**F1-macro, uji statistik**	—	—

Baris B–D adalah ilustrasi format; isi dengan paper nyata hasil penelusuran Anda.

> **Gap** yang muncul: data lapangan terbatas + perbandingan yang adil + uji signifikansi + analisis kesalahan.

Menulis Penelitian Terkait secara Kritis

✗ **Gaya daftar** (sering ditemui):

> *"Mohanty (2016) melakukan penelitian … hasilnya 99%. Kemudian Studi B (2021) melakukan … hasilnya 95%. Selanjutnya Studi C …"*

✓ **Gaya sintesis** (dikelompokkan berdasarkan tema):

> *"Sebagian besar studi klasifikasi penyakit tanaman memperoleh akurasi di atas 95% (Mohanty dkk., 2016; B, 2021), namun dievaluasi pada citra berlatar seragam. Ketika diuji pada citra lapangan, kinerja menurun tajam (Mohanty dkk., 2016). Studi yang memakai citra lapangan (C, 2023) belum membandingkan dengan transfer learning, sementara pendekatan ViT (D, 2024) membutuhkan data besar…"*

> Paragraf yang baik **membandingkan, mengelompokkan, dan menilai** — lalu berakhir pada **celah** yang diisi penelitian Anda.

Landasan Teori: Tulis yang Dipakai, dengan Notasi Konsisten

Contoh — fungsi loss *cross-entropy* untuk klasifikasi K kelas:

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{k=1}^{K} y_{ik}\,\log \hat{y}_{ik}, \qquad \hat{y}_{ik} = \frac{e^{z_{ik}}}{\sum_{j=1}^{K} e^{z_{ij}}}$$

Contoh — F1-macro (rata-rata F1 tiap kelas, adil untuk data tidak seimbang):

$$\mathrm{F1}_k = \frac{2\,P_k R_k}{P_k + R_k}, \qquad \mathrm{F1}_{\text{macro}} = \frac{1}{K}\sum_{k=1}^{K} \mathrm{F1}_k$$

- Setiap simbol **didefinisikan** saat pertama muncul.
- Gambar arsitektur: buat ulang sendiri atau cantumkan sumber ("diadaptasi dari …").

Bab 3. Metodologi Penelitian

Rancangan yang membuat hasil **valid dan dapat diulang**

Tahapan Penelitian (Diagram Alir)

No	Tahap	Keluaran	Subbab
1	Studi literatur & perumusan masalah	Hipotesis, rancangan eksperimen	3.1
2	Pengumpulan data	Dataset mentah + dokumentasi sumber & lisensi	3.2
3	Eksplorasi data (EDA)	Distribusi kelas, kualitas, contoh citra	3.3
4	Pra-pemrosesan & pembagian data	Train / validation / test **terkunci**	3.4
5	Pemodelan	Baseline + model usulan	3.5
6	Skenario eksperimen	Daftar run (perbandingan, tuning, ablation)	3.6
7	Evaluasi	Metrik + uji statistik + error analysis	3.7
8	Lingkungan & reproducibility	Spesifikasi HW/SW, seed, tracking	3.8

> Di naskah: gambarkan sebagai **flowchart**; setiap kotak dijelaskan dalam satu subbab. Pembaca lain harus bisa **mengulang** penelitian hanya dari Bab 3.

3.2 Pengumpulan Data

Hal	Yang wajib dijelaskan
Sumber	Nama dataset publik + sitasi/URL, atau prosedur akuisisi sendiri (alat, lokasi, waktu)
Lisensi & izin	Lisensi dataset (CC-BY, dsb.), izin pengambilan data, persetujuan subjek (*informed consent*) bila melibatkan manusia
Ukuran & struktur	Jumlah sampel, kelas, resolusi/panjang teks, format
Pelabelan	Siapa pelabel (pakar? mahasiswa?), panduan anotasi, jumlah anotator
Kualitas label	Kesepakatan antar-anotator, mis. **Cohen's κ**: $\kappa = \frac{p_o - p_e}{1 - p_e}$ (κ > 0,6 cukup baik)
Privasi	Anonimisasi data pribadi (nama, NIK, wajah, nomor HP)

Data adalah **kontribusi besar** skripsi ML. Dokumentasikan dengan *datasheet* sederhana (Gebru dkk., 2021): motivasi, komposisi, proses pengumpulan, penggunaan yang disarankan.

3.3 Exploratory Data Analysis (EDA)

Tujuan EDA di skripsi: **mengenali sifat data** yang memengaruhi pilihan metode.

- **Distribusi kelas** — seimbang atau tidak? → menentukan metrik (F1-macro, bukan akurasi) dan strategi (*class weight*, *oversampling*).
- **Kualitas data** — duplikat, citra blur/rusak, label salah, nilai hilang, *outlier*.
- **Karakteristik** — ukuran citra, panjang teks, korelasi fitur (tabular).
- **Potensi kebocoran** — citra yang sama/hampir sama di dua kelas atau dua split; foto beruntun dari daun yang sama.

Kelas	Jumlah	%
Blas	420	35,0
Hawar daun	360	30,0
Tungro	180	15,0
Sehat	240	20,0

Contoh tabel distribusi (ilustrasi). Kelas tungro minoritas → perhatikan recall-nya.

3.4 Pembagian Data & Mencegah *Data Leakage*

Aturan emas: test set **disisihkan di awal**, tidak disentuh sampai evaluasi akhir.

Skema	Kapan dipakai
Hold-out 70/15/15 (stratified)	Data cukup besar (ribuan+)
Stratified k-fold CV (k = 5 atau 10) + test terpisah	Data kecil; ingin estimasi variansi
Group split (per daun/pasien/pengguna)	Ada beberapa sampel dari sumber yang sama
Time-based split	Data deret waktu / berurutan

Bentuk kebocoran yang sering terjadi:

- Normalisasi/scaler/TF-IDF di-*fit* pada **seluruh** data sebelum split → *fit* hanya pada train.
- Augmentasi dilakukan **sebelum** split → duplikat hasil augmentasi bocor ke test.
- Foto beruntun dari **daun yang sama** tersebar di train dan test → gunakan *group split*.
- Memilih hyperparameter berdasarkan nilai **test** → gunakan validation.

> Kebocoran data adalah penyebab paling umum hasil "terlalu bagus untuk jadi kenyataan" (Kapoor & Narayanan, 2023).

3.4 Pra-pemrosesan: Tulis Secara Rinci & Berurutan

Langkah	Citra (contoh)	Teks (contoh)	Tabular (contoh)
Pembersihan	Hapus duplikat/blur	Hapus URL, emoji, duplikat	Tangani nilai hilang
Normalisasi	Resize 224×224, normalisasi mean/std ImageNet	*Case folding*, normalisasi slang	Standardisasi z-score
Representasi	Tensor RGB	Tokenisasi WordPiece (IndoBERT)	*One-hot* / *target encoding*
Augmentasi (train saja)	Flip, rotasi ±20°, *color jitter*	*Back-translation*, EDA	SMOTE (hanya di train fold)

> Tulis parameter **persis** (ukuran, rentang rotasi, probabilitas). "Dilakukan augmentasi" saja **tidak cukup** untuk direproduksi.

3.5 Pemodelan: Baseline Itu Wajib

Tanpa baseline, angka "akurasi 95%" **tidak bermakna** — 95% dibanding apa?

Tingkat	Contoh (citra)	Contoh (teks)	Fungsi
Trivial	Tebak kelas mayoritas	Tebak kelas mayoritas	Batas bawah (akurasi 35% pada contoh EDA)
Klasik	Fitur warna/tekstur (GLCM) + SVM/Random Forest	TF-IDF + Logistic Regression	Apakah DL memang diperlukan?
DL sederhana	CNN 3–4 layer dari awal	BiLSTM	Pembanding untuk transfer learning
Usulan	EfficientNet-B0 / ResNet-50 (TL)	IndoBERT *fine-tuning*	Model yang diuji hipotesisnya
SOTA (opsional)	ViT, ConvNeXt	XLM-R large	Posisi terhadap batas atas

> Jelaskan setiap model: arsitektur, jumlah parameter, bobot awal (*pretrained* dari mana), layer yang dibekukan/di-*fine-tune*, fungsi loss, optimizer.

3.6 Skenario Eksperimen

Turunkan langsung dari hipotesis. **Ubah satu faktor pada satu waktu**; faktor lain dikunci.

Skenario	Faktor yang diubah	Yang dikunci	Menjawab
S1 — Perbandingan model	CNN-scratch vs ResNet-50 vs EfficientNet-B0	Data split, augmentasi, epoch maks, early stopping	H1 / RM1
S2 — Ukuran data	25%, 50%, 100% data latih	Model terbaik S1	RM1 (data terbatas)
S3 — Ablation augmentasi	Dengan vs tanpa augmentasi; jenis augmentasi	Model & data	H2 / RM2
S4 — Tuning	lr ∈ {1e-4, 3e-4, 1e-3}, batch ∈ {16, 32}	Pada validation set saja	Konfigurasi akhir

- Setiap konfigurasi dijalankan dengan **≥ 3-5 seed** (atau 5-fold CV) → laporkan **mean ± std**.
- Hitung **anggaran komputasi**: 3 model × 5 seed × ±20 menit ≈ 5 jam GPU untuk S1 saja. Rencanakan!

3.6 Tuning Hyperparameter yang Adil

Prinsip	Penjelasan
Anggaran sama	Setiap model mendapat jumlah *trial* tuning yang setara — jangan tuning model usulan 50 kali tetapi baseline 1 kali
Hanya di validation	Test set tidak dipakai untuk memilih konfigurasi
Ruang pencarian ditulis	Cantumkan rentang/nilai yang dicoba + metode (grid, random, Bayesian/Optuna)
Early stopping	Pantau `val_loss`, *patience* mis. 10 epoch; simpan bobot terbaik
Konfigurasi akhir dilaporkan	Tabel hyperparameter final setiap model (lampiran)

```
Ruang pencarian (contoh):
  learning_rate : log-uniform [1e-5, 1e-2]
  batch_size    : {16, 32, 64}
  dropout       : uniform [0.0, 0.5]
  optimizer     : {AdamW}, weight_decay = 1e-4
  metode        : Random search, 30 trial per model, metrik = val F1-macro
```

3.7 Memilih Metrik Evaluasi

Tugas	Metrik utama	Metrik pendukung
Klasifikasi seimbang	Akurasi, F1-macro	Precision, recall per kelas, confusion matrix
Klasifikasi **tidak seimbang**	**F1-macro**, PR-AUC, *balanced accuracy*	Recall kelas minoritas
Diagnosis (biaya FN tinggi)	**Recall/sensitivity**	Specificity, ROC-AUC
Regresi	RMSE, MAE	R^2, plot residual
Deteksi objek	mAP@0,5, mAP@0,5:0,95	Precision–recall per kelas
Segmentasi	IoU / Dice	Pixel accuracy
Generasi teks / ringkasan	ROUGE, BLEU, BERTScore	Evaluasi manusia
Clustering	Silhouette, ARI/NMI (bila ada label)	Interpretasi klaster

> Tetapkan **satu metrik utama sebelum eksperimen** (di proposal). Mengganti metrik setelah melihat hasil = *metric shopping*.
>
> Jika relevan, laporkan juga **efisiensi**: jumlah parameter, waktu inferensi, ukuran model.

3.7 Uji Statistik: "Lebih Tinggi" Belum Tentu "Lebih Baik"

Situasi	Uji yang disarankan
2 model, skor dari k-fold/seed yang sama (berpasangan)	**Wilcoxon signed-rank** (non-parametrik) atau *paired t-test*
2 model, satu test set, prediksi per sampel	**McNemar test**
≥ 3 model pada beberapa fold/dataset	**Friedman** + post-hoc **Nemenyi** (Demšar, 2006)
Ketidakpastian satu metrik	**Bootstrap 95% CI**

Contoh hasil 5-fold (ilustrasi):

Fold	1	2	3	4	5	Mean ± Std
CNN-scratch	0,781	0,764	0,792	0,770	0,758	0,773 ± 0,014
EfficientNet-B0 (TL)	0,872	0,861	0,889	0,866	0,853	0,868 ± 0,014

TL lebih tinggi di **kelima fold** → Wilcoxon satu sisi, $W^+ = 15, p = 1/2^5 = 0{,}031 < 0{,}05$ → **H_0 ditolak**.

> Catatan: dengan n = 5, nilai p terkecil yang mungkin adalah 0,031 — pertimbangkan 10-fold atau lebih banyak seed.

3.8 Lingkungan & Reproducibility

Komponen	Yang dicatat	Alat
Kode	Repositori + *commit hash* untuk setiap hasil	Git, GitHub/GitLab
Data	Versi/hash dataset & berkas split	DVC, W&B Artifacts, simpan `split.csv`
Konfigurasi	Semua hyperparameter, termasuk seed	Berkas YAML, `wandb.config`
Lingkungan	Versi Python & library, CUDA, GPU	`requirements.txt` / `environment.yml`, Docker
Eksperimen	Metrik per epoch, artefak model, log	**Weights & Biases**, MLflow, TensorBoard

```python
import random, numpy as np, torch
def set_seed(seed: int = 42):
    random.seed(seed); np.random.seed(seed)
    torch.manual_seed(seed); torch.cuda.manual_seed_all(seed)
    torch.backends.cudnn.deterministic = True
    torch.backends.cudnn.benchmark = False
```

> Target minimal skripsi: orang lain dapat menjalankan `git clone` → `pip install -r requirements.txt` → `python train.py --config configs/s1_effnet.yaml` dan memperoleh hasil yang **mendekati** tabel di Bab 4.

Struktur Repositori yang Disarankan

```
skripsi-padi/
├── README.md              # cara instalasi, menjalankan, dan mereproduksi tabel Bab 4
├── requirements.txt       # versi library terkunci
├── configs/               # satu YAML per skenario: s1_cnn.yaml, s1_effnet.yaml, ...
├── data/
│   ├── raw/               # TIDAK di-commit (gunakan DVC / tautan unduhan)
│   ├── processed/
│   └── splits/            # train.csv, val.csv, test.csv  → DI-COMMIT (kecil, penting)
├── notebooks/             # 01_eda.ipynb, 05_error_analysis.ipynb (eksplorasi saja)
├── src/
│   ├── data.py            # dataset, transform, augmentasi
│   ├── models.py          # definisi arsitektur
│   ├── train.py           # loop training + logging (wandb)
│   └── evaluate.py        # metrik, confusion matrix, uji statistik
├── results/               # tabel & gambar final untuk naskah
└── thesis/                # naskah (LaTeX/Word) & slide sidang
```

> Notebook untuk **eksplorasi**; skrip `.py` + konfigurasi untuk **eksperimen resmi** yang hasilnya masuk naskah.

Bab 4. Hasil dan Pembahasan

Hasil = **apa** yang terjadi · Pembahasan = **mengapa** dan **apa artinya**

Struktur Bab 4

Subbab	Isi
4.1 Hasil eksplorasi & pra-pemrosesan data	Statistik akhir dataset, contoh hasil augmentasi
4.2 Hasil skenario 1 — perbandingan model	Tabel utama + uji statistik → **jawab RM1/H1**
4.3 Hasil skenario 2–3 — ukuran data & ablation	Grafik & tabel → **jawab RM2/H2**
4.4 Analisis kesalahan & interpretabilitas	Confusion matrix, contoh salah, Grad-CAM → **jawab RM3**
4.5 Pembahasan	Kaitkan dengan premis & penelitian terdahulu; keterbatasan

> Urutkan subbab **mengikuti rumusan masalah**, bukan mengikuti urutan Anda melakukan eksperimen.

Menyajikan Tabel Hasil Utama

Tabel 4.2 Kinerja model pada test set (mean ± std dari 5 seed). **Tebal** = terbaik.

Model	Param (juta)	Akurasi	F1-macro	Recall Tungro	Waktu inferensi (ms/citra)
Kelas mayoritas	—	0,350	0,130	0,000	—
GLCM + SVM	—	0,712 ± 0,000	0,664 ± 0,000	0,51	3
CNN-scratch	1,2	0,801 ± 0,015	0,773 ± 0,014	0,62	4
ResNet-50 (TL)	23,5	0,889 ± 0,010	0,861 ± 0,012	0,78	18
EfficientNet-B0 (TL)	4,0	**0,896 ± 0,009**	**0,868 ± 0,014**	**0,81**	9

Angka ilustrasi.

- Sertakan **baseline**, **variansi**, satuan, dan keterangan apakah dari validation atau test.
- Gunakan **angka penting yang konsisten** (3 desimal) dan desimal koma sesuai PUEBI bila naskah berbahasa Indonesia.

Grafik yang Bercerita

Pertanyaan	Grafik yang tepat
Apakah training stabil / overfitting?	**Learning curve** train vs val loss per epoch
Model mana lebih baik?	**Bar chart** dengan *error bar* (std atau 95% CI)
Bagaimana pengaruh ukuran data?	**Line chart** F1 vs % data latih per model
Kelas mana yang tertukar?	**Confusion matrix** (dinormalisasi per baris)
Trade-off kinerja vs biaya	**Scatter** F1 vs waktu inferensi / jumlah parameter
Ke mana model "melihat"?	**Grad-CAM** pada contoh benar & salah

> Setiap gambar: judul/keterangan lengkap, label sumbu + satuan, legenda, ukuran font terbaca, dan **dirujuk dan dibahas di teks** ("Gambar 4.3 menunjukkan…").

Pembahasan: Dari Angka ke Makna

Pola **4 langkah** untuk setiap temuan:

1. **Nyatakan hasil** — *"EfficientNet-B0 mencapai F1-macro 0,868, lebih tinggi 0,095 dari CNN-scratch (Tabel 4.2); perbedaan signifikan (Wilcoxon, p = 0,031)."*
2. **Jelaskan mengapa** — *"Sejalan dengan P1–P2: fitur tekstur dari ImageNet dapat dipindahkan, sehingga model tidak perlu belajar dari 1.200 citra saja."*
3. **Bandingkan dengan literatur** — *"Hasil ini lebih rendah dari 99% pada Mohanty dkk. (2016) karena citra lapangan memiliki latar yang beragam, konsisten dengan penurunan kinerja yang juga mereka laporkan."*
4. **Implikasi & batasan** — *"Recall tungro (0,81) masih terendah; untuk penggunaan lapangan, kesalahan pada kelas ini perlu diwaspadai."*

> **Hipotesis harus dijawab eksplisit**: "H_1 **diterima**" atau "H_1 **tidak didukung** oleh data". Hasil negatif tetap kontribusi — laporkan dengan jujur.

Analisis Kesalahan (*Error Analysis*)

Nilai tambah besar skripsi: memahami **di mana dan mengapa** model gagal.

Confusion matrix (dinormalisasi per baris, ilustrasi):

Aktual \ Prediksi	Blas	Hawar	Tungro	Sehat
Blas	**0,91**	0,06	0,02	0,01
Hawar	0,05	**0,89**	0,04	0,02
Tungro	0,03	0,11	**0,81**	0,05
Sehat	0,01	0,02	0,03	**0,94**

Langkah analisis:

1. Temukan pasangan kelas yang paling sering tertukar (**tungro → hawar**, 11%).
2. Ambil 20–30 contoh salah; kelompokkan penyebabnya: label keliru? citra buram? gejala mirip? pencahayaan?
3. Visualisasikan dengan **Grad-CAM**: apakah model melihat bercak, atau justru latar (tanah, tangan)?
4. Ubah temuan menjadi **saran** konkret (data tambahan kelas tungro, augmentasi warna, dsb.).

Ablation Study: Komponen Mana yang Berpengaruh?

Tabel 4.4 Ablation pada EfficientNet-B0, 100 citra/kelas (val F1-macro, mean ± std, 5 seed — ilustrasi).

Konfigurasi	Pretrained	Augmentasi	Class weight	F1-macro	Δ
Lengkap	✓	✓	✓	**0,842 ± 0,013**	—
– Pretrained	✗	✓	✓	0,701 ± 0,021	–0,141
– Augmentasi	✓	✗	✓	0,796 ± 0,018	–0,046
– Class weight	✓	✓	✗	0,829 ± 0,012	–0,013

Pembahasan: bobot *pretrained* paling berpengaruh; augmentasi berpengaruh nyata pada data kecil (→ **H2 diterima** bila signifikan); *class weight* berpengaruh kecil.

> Ablation mengubah klaim "model kami bagus" menjadi "**komponen X** yang membuatnya bagus".

Bab 5. Kesimpulan dan Saran

Kesimpulan: Jawaban Langsung atas Rumusan Masalah

- Jumlah poin kesimpulan = jumlah rumusan masalah; **urutan sama**.
- Berisi **jawaban + angka kunci**, bukan ringkasan proses.
- **Tidak** memuat hal baru yang tidak dibahas di Bab 4.

✗ Bukan kesimpulan	✓ Kesimpulan
"Penelitian ini telah berhasil membuat model deteksi penyakit padi menggunakan EfficientNet."	"1. Transfer learning EfficientNet-B0 menghasilkan F1-macro 0,868 ± 0,014, lebih tinggi secara signifikan dibanding CNN dari awal (0,773 ± 0,014; Wilcoxon $p = 0{,}031$), sehingga H_1 diterima."
"Augmentasi itu penting."	"2. Pada 100 citra/kelas, augmentasi meningkatkan F1-macro sebesar 0,046 …"

Saran: Konkret dan Berbasis Temuan

Saran yang baik **lahir dari keterbatasan dan hasil error analysis**, bukan daftar umum.

✗ Umum	✓ Spesifik & beralasan
"Gunakan data yang lebih banyak."	"Tambah minimal 300 citra **tungro** lapangan karena 11% tungro salah diklasifikasikan sebagai hawar (Tabel 4.3)."
"Coba metode lain."	"Uji model deteksi objek (YOLO) agar bercak terlokalisasi, karena Grad-CAM menunjukkan model kadang memperhatikan latar."
"Kembangkan aplikasi."	"Evaluasi di lapangan bersama penyuluh untuk mengukur kinerja pada kamera HP berkualitas rendah."

6. Manajemen Penelitian

Jadwal · Bimbingan · Tools · Etika · Checklist

Contoh Jadwal (2 Semester)

Bulan	Kegiatan	Milestone bimbingan
1	Eksplorasi topik, baca 20+ paper, matriks literatur	Topik & 3 kandidat rumusan masalah
2	Draf Bab 1–3, pilih dataset, EDA awal	**Seminar proposal**
3	Pipeline data + split terkunci + baseline	Tabel baseline
4	Eksperimen S1 (perbandingan model)	Hasil S1 + learning curves
5	Eksperimen S2–S4 (data, ablation, tuning)	Tabel ablation
6	Uji statistik, error analysis, Grad-CAM	Draf Bab 4
7	Penulisan Bab 4–5, revisi Bab 1–3	**Seminar hasil**
8	Revisi, cek plagiarisme, arsip kode & data, slide sidang	**Sidang**

Tools yang Disarankan

Kebutuhan	Tools
Komputasi	Google Colab, Kaggle Notebooks (GPU gratis terbatas), server lab/prodi
Framework	PyTorch / TensorFlow-Keras, scikit-learn, HuggingFace Transformers, timm
Tracking eksperimen	**Weights & Biases**, MLflow, TensorBoard
Versi kode & data	Git + GitHub, DVC / W&B Artifacts
Anotasi data	Label Studio, CVAT, Roboflow
Uji statistik	`scipy.stats` (wilcoxon, friedmanchisquare), `scikit-posthocs`, `mlxtend` (McNemar)
Interpretabilitas	Grad-CAM (`pytorch-grad-cam`), SHAP, LIME
Referensi	Zotero / Mendeley (+ plugin Word/LaTeX)
Penulisan	LaTeX (Overleaf) atau Word dengan *styles* & *caption* otomatis

Etika, Integritas, dan Penggunaan AI Generatif

Aspek	Praktik yang benar
Data pribadi	Anonimisasi; patuhi UU PDP No. 27/2022; *informed consent* untuk data manusia
Lisensi	Patuhi lisensi dataset & model *pretrained*; cantumkan sitasi
Bias & fairness	Laporkan kinerja per subkelompok bila relevan (wilayah, gender, dialek)
Integritas hasil	Jangan memilih seed/fold terbaik saja; laporkan semua skenario termasuk yang gagal
Plagiarisme	Parafrase + sitasi; cek dengan Turnitin sesuai ketentuan prodi
AI generatif (ChatGPT, Claude, Copilot)	Boleh sebagai **alat bantu** (debug, perbaikan bahasa) sesuai kebijakan kampus; **ungkapkan penggunaannya**; Anda tetap **bertanggung jawab penuh** atas isi; **verifikasi** setiap sitasi — AI dapat mengarang referensi

> Anda harus dapat **menjelaskan setiap baris kode dan setiap kalimat** di naskah saat sidang.

10 Kesalahan Paling Sering pada Skripsi ML/DL

#	Kesalahan	Akibat
1	Tidak ada baseline	Hasil tidak dapat dinilai
2	Data leakage (scaler/augmentasi sebelum split, duplikat)	Hasil terlalu optimistis
3	Memakai test set untuk tuning	Estimasi kinerja bias
4	Hanya akurasi pada data tidak seimbang	Kelas minoritas "hilang"
5	Satu kali run, tanpa variansi	Klaim tidak dapat dipercaya
6	Perbandingan tidak adil (tuning berbeda, data berbeda)	Kesimpulan keliru
7	Membandingkan angka dengan paper lain pada **dataset berbeda**	Perbandingan tidak sahih
8	Rumusan masalah tidak terjawab di kesimpulan	Inkonsistensi naskah
9	Kode/konfigurasi tidak tersimpan	Tidak dapat direproduksi saat revisi
10	Bab 2 berisi teori panjang yang tidak dipakai	Naskah tebal, isi tipis

Checklist Sebelum Seminar Hasil / Sidang

Naskah

- ✓ Setiap rumusan masalah → tujuan → subbab Bab 4 → poin kesimpulan saling terhubung
- ✓ Hipotesis dinyatakan diterima/ditolak secara eksplisit
- ✓ Matriks literatur & *research gap* jelas
- ✓ Semua gambar/tabel dirujuk dan dibahas di teks
- ✓ Notasi & istilah konsisten; daftar pustaka lengkap dan terverifikasi
- ✓ Lolos cek plagiarisme

Eksperimen

- ✓ Test set tidak disentuh selama pengembangan
- ✓ Ada baseline trivial, klasik, dan DL sederhana
- ✓ Mean ± std dari ≥ 5 seed / k-fold; uji statistik
- ✓ Ablation & error analysis
- ✓ Repositori: README, `requirements.txt`, config, split, skrip untuk mereproduksi tabel
- ✓ Dataset & model terbaik terarsip (W&B/Drive/Zenodo)

> Simulasikan sidang: minta teman bertanya "**mengapa** memilih metode/metrik/split ini?" — pertanyaan *mengapa* adalah inti sidang.

Pertanyaan Sidang yang Sering Muncul

Pertanyaan	Persiapan jawaban
Apa kontribusi penelitian Anda?	1–2 kalimat yang merujuk *research gap*
Mengapa memakai model ini, bukan X?	Alasan dari literatur + bukti dari eksperimen pembanding
Mengapa memakai metrik ini?	Sifat data (tidak seimbang) & kebutuhan domain
Bagaimana memastikan tidak ada data leakage?	Prosedur split, *fit* pra-pemrosesan hanya di train, cek duplikat
Apakah perbedaan hasil signifikan?	Uji statistik + mean ± std
Mengapa model salah pada kelas tertentu?	Error analysis + Grad-CAM
Apakah model bisa dipakai di dunia nyata?	Batasan evaluasi + saran uji lapangan
Bagaimana jika data ditambah / domain berbeda?	Hasil skenario ukuran data + keterbatasan generalisasi

Ringkasan

1. Skripsi ML/DL adalah **penelitian eksperimental**: pertanyaan → hipotesis → eksperimen terkontrol → jawaban.
2. **Bab 1**: masalah spesifik, premis bersitasi, hipotesis yang dapat diuji, tujuan = cermin masalah, batasan yang beralasan.
3. **Bab 2**: matriks literatur dan sintesis kritis → *research gap*; teori hanya yang dipakai.
4. **Bab 3**: split dengan aturan yang jelas tanpa kebocoran, **baseline**, skenario yang adil, metrik yang tepat, uji statistik, reproducibility.
5. **Bab 4**: hasil → mengapa → bandingkan literatur → implikasi; ablation & error analysis.
6. **Bab 5**: jawaban langsung atas rumusan masalah + saran yang lahir dari temuan.

> *"Hasil yang baik bukan yang angkanya tertinggi, melainkan yang **jujur, dapat diulang, dan dapat dijelaskan**."*

Referensi

1. Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *JMLR*, 7, 1–30.
2. Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7), 1895–1923.
3. Gebru, T., dkk. (2021). Datasheets for datasets. *Communications of the ACM*, 64(12), 86–92.
4. Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, 4(9), 100804.
5. Lones, M. A. (2024). Avoiding common machine learning pitfalls. *Patterns*, 5(10). (versi arXiv: 2108.02497)
6. Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419.
7. Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. *IEEE TKDE*, 22(10), 1345–1359.
8. Pineau, J., dkk. (2021). Improving reproducibility in machine learning research. *JMLR*, 22(164), 1–20.
9. Selvaraju, R. R., dkk. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *ICCV*.
10. Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *NeurIPS*.
11. Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *ICML*.

Terima Kasih

> *Hasil yang baik bukan yang angkanya tertinggi, melainkan yang jujur, dapat diulang, dan dapat dijelaskan.*